
DETECÇÃO DE DANOS ESTRUTURAIS EM PONTES ATRAVÉS DE REDES NEURAIS ARTIFICIAIS

 **Daniele Kautz Monteiro**

Programa de Pós-Graduação em Engenharia Civil
Universidade Federal do Rio Grande do Sul
Porto Alegre, RS
daniele.kautz@ufrgs.br

Gabriel Moreira Beretta

Programa de Pós-Graduação em Computação
Universidade Federal do Rio Grande do Sul
Porto Alegre, RS
gabriel.beretta@inf.ufrgs.br

Juliano Pardelinas Cardoso

Programa de Pós-Graduação em Computação
Universidade Federal do Rio Grande do Sul
Porto Alegre, RS
jpcardoso@inf.ufrgs.br

Fevereiro, 2024

RESUMO

Este artigo propõe uma abordagem para a detecção de danos estruturais em pontes, combinando o pré-processamento de sinais provenientes de acelerômetros distribuídos na estrutura, a transformação desses sinais em imagens de grades sinusoidais e a aplicação de Redes Neurais Convolucionais (CNN) pré-treinadas. O estudo concentrou-se na Ponte Old ADA, localizada na província de Nara, Japão. Foram empregadas as arquiteturas de redes neurais Resnet50, DenseNet e InceptionV3 para classificar a presença ou ausência de danos. O modelo DenseNet destacou-se, alcançando uma acurácia de 95,06% nos conjuntos de dados de validação e teste; no entanto, os demais modelos também apresentaram acurácias superiores a 90,00%. Além disso, observou-se que a posição dos sensores ao longo da extensão da ponte e o tipo de vibração do sistema não foram fatores determinantes na precisão do modelo. Esses resultados indicam a eficácia da metodologia proposta na identificação precoce de potenciais problemas estruturais na ponte.

Palavras-chave Detecção de dano · Redes Neurais Convolucionais · Pontes

1 Introdução

As pontes desempenham um papel fundamental na infraestrutura, conectando comunidades e facilitando o transporte. Entretanto, ao longo do tempo, essas estruturas estão suscetíveis a danos estruturais, resultantes de diversos fatores como desgaste natural e eventos extremos ([Zhang and Yuen, 2022]). A detecção precoce desses danos é crucial para garantir a segurança pública e prolongar a vida útil das pontes.

O Monitoramento de Integridade Estrutural (*Structural Health Monitoring* - SHM) começou por volta dos anos 2000, buscando acompanhar pontes e demais estruturas para fornecer dados quantitativos e confiáveis sobre suas integridades ([Shibu et al., 2023]). Desde então, muitos estudos sobre SHM tem surgido, sendo vários deles com a utilização de inteligência artificial para detectar, localizar e quantificar danos ([Weinstein et al., 2018], [Athar et al., 2020], [Nick et al., 2021]).

Nesse contexto, esse trabalho propõe uma abordagem com Redes Neurais Convolucionais para classificar a presença ou não de dano na Ponte Old ADA. Como dados de entrada, são utilizados os sinais de aceleração ao longo do tempo, provenientes de sensores distribuídos na estrutura da ponte que detectam as vibrações do sistema. Entretanto, diferentemente de outros trabalhos ([Santaniello and Russo, 2023]), aqui é proposto a transformação desses sinais em

imagens de grades sinusoidais a partir da Transformada Rápida de Fourier para o treinamento da rede. Essas imagens refletem as frequências naturais da estrutura analisada, os quais são parâmetros sensíveis ao dano. Além disso, as imagens são obtidas a partir de sensores posicionados em diferentes locais da estrutura, onde a localização do sensor e a intensidade da vibração não são fatores determinantes para o sucesso da metodologia.

A organização desse trabalho é descrita a seguir. Na Seção 2, tem-se um panorama geral da ponte utilizada para o estudo, com detalhes da estrutura e como os danos foram gerados no sistema para o estudo. Em seguida, os pré-processamentos dos dados utilizados no trabalho são explicados em detalhes na Seção 3. Na Seção 4, é explicado como foi feita a detecção de danos com 3 arquiteturas diferentes de redes neurais. Os resultados obtidos com a rede neural são apresentados e discutidos na Seção 5. Por fim, na Seção 6, são feitas as considerações finais com sugestões para trabalhos futuros.

2 Ponte Old ADA

Este artigo teve como objeto de estudo a Ponte Old ADA, localizada na província de Nara (Japão). A estrutura treliçada de aço simplesmente apoiada foi removida em 2012, após 53 anos de uso, sendo previamente realizados ensaios experimentais de vibração. Esses ensaios fizeram parte de um estudo visando gerar dados para identificação de sistemas e avaliação de dano ([Kim et al., 2021a]).

Como apresenta a Figura 1, a coleta de dados ocorreu por meio de oito sensores (acelerômetros), que armazenaram sinais de aceleração ao longo do tempo durante a execução de testes para 5 estados: (a) estado íntegro, (b) estado de dano 1, (c) estado de dano 2, (d) estado recuperado, (e) estado de dano 3. Os ensaios foram repetidos diversas vezes considerando a vibração de veículos em diferentes velocidades (30 km/h, 40 km/h, 50 km/h), além de vibração ambiental.




Figura 1: Ponte Old ADA: (a) localização dos sensores, (b) estados de dano.

Os danos foram executados artificialmente em barras verticais da ponte. Nos estados de dano 1 e 2, respectivamente, uma das barras de meio de vão ($x = 29,6$ m) teve sua seção cortada parcialmente e integralmente. Em sequência, esses danos foram reparados no estado recuperado. Já no estado de dano 3, ocorreu o corte total de uma seção de uma das barras localizadas em $x = 37$ m (Figura 1). Mais informações sobre a Ponte Old ADA e os ensaios executados estão disponíveis em Kim et al. [2021a].

3 Pré-processamento de dados

Os dados dos ensaios da Ponte Old ADA foram disponibilizados em um arquivo do Matlab (Old_ADA_Bridgedamage_vibration_data.mat), de acordo com o tipo de vibração (ambiental ou induzida por veículos), estados de dano e repetições dos ensaios ([Kim et al., 2021b]). Esses dados foram pré-processados, buscando definir o conjunto de dados a ser utilizado nas análises deste trabalho.

Como os ensaios experimentais não tiveram a mesma duração de tempo, dividiu-se todos os sinais de aceleração a cada 1000 pontos. Os sinais derivados dessa divisão são equivalentes a 5 segundos (Figura 2(a)), já que a frequência de

aquisição dos testes foi de 200 Hz. Em sequência, aplicou-se nesses sinais a Transformada Rápida de Fourier (FFT). Essa transformada apresenta a potência de cada frequência naquele sinal, ou seja, as frequências em que a estrutura está respondendo a excitação. Em cada acelerograma, a intensidade de cada frequência pode variar de acordo com a excitação atuante no sistema, além da presença ou não de dano. Destaca-se que foi considerado apenas o trecho de 0 a 15 Hz da FFT de cada sinal, pois as primeiras cinco frequências da ponte analisada se encontram nesse limite (Figura 2(b)), como mostrado em He et al. [2022].

Para gerar os dados de entrada da rede, as FFTs foram convertidas em imagens de grades sinusoidais. Essa representação visual preserva as propriedades dos dados originais de forma espacial. Assim, as frequências naturais dos sinais são representadas por:

$$y = \sin \frac{2\pi x}{\lambda}, \quad (1)$$

onde y são as coordenadas das ondas, x são as coordenadas da Transformada Rápida de Fourier de cada sinal e λ é igual ao comprimento de onda (nesse trabalho adotado igual a 200).

Dessa forma, pode-se gerar a imagem de cada sinal com as coordenadas x e y (Figura 2(c)). O conjunto de dados final contou com 7700 imagens de 150x150x3 (4277 imagens sem dano e 3423 imagens com dano), que foram produzidas a partir dos acelerômetros 2 a 8.

A Figura 3 apresenta exemplos das imagens geradas para o estado íntegro e o estado com dano. Nota-se que as regiões das frequências predominantes da ponte tendem a aparecer nas imagens com algum tipo de coloração diferente da coloração majoritária da imagem, e.g. $f_n \approx 3$ Hz.

4 Detecção de danos por redes neurais

A detecção de danos por meio de redes neurais é uma aplicação comum de técnicas de aprendizado de máquina, como visão computacional e aprendizado profundo. Neste trabalho, a abordagem utilizada se baseia em algoritmos de redes neurais para analisar imagens das respostas da estrutura em diferentes cenários, identificando a presença ou não de dano.

Redes neurais são modelos computacionais inspirados na estrutura e funcionamento do sistema nervoso biológico para realização de tarefas específicas de aprendizado e reconhecimento de padrões. Segundo Goodfellow et al. [2016] as redes neurais são sistemas computacionais compostos por unidades interconectadas, modeladas de acordo com a organização de neurônios no cérebro e que são capazes de aprender representações complexas a partir de dados.

4.1 Rede Neural Convolutacional

Existem diversas arquiteturas de redes neurais, dentre elas, a Rede Neural Convolutacional (*Convolutional Neural Network* - CNN), relacionada principalmente à visão computacional. As CNNs são projetadas para processar dados bidimensionais, sendo eficazes na extração de padrões e características relevantes em imagens.

A utilização de CNNs com o uso de imagens de grades sinusoidais surge como uma alternativa para detectar possíveis danos em estruturas, pois essas imagens proporcionam uma representação visual das frequências dos sinais de aceleração, permitindo capturar padrões visuais específicos associados a diferentes tipos e níveis de danos.

Existem diversas arquiteturas de CNNs que representam o estado da arte em tarefas envolvendo imagens, sendo as aplicadas neste trabalho:

- ResNet50;
- DenseNet;
- InceptionV3.

4.1.1 Resnet50

ResNet é a uma arquitetura específica de rede neural convolutacional que foi introduzida por He et al. [2016], onde o nome ResNet é uma abreviação de *Residual Networks*. A arquitetura ResNet50 possui 50 camadas e é conhecida por sua profundidade e desempenho em tarefas de visão computacional, como classificação de imagens. Ela consiste em vários blocos residuais, cada um composto por camadas convolucionais, normalização de lote (*batch normalization*) e ativações ReLU (*Rectified Linear Unit*).




Figura 2: Exemplo de dado: (a) sinal de aceleração, (b) transformada rápida de Fourier e (c) imagem de grades sinusoidais.

Essa arquitetura se tornou popular para transferência de aprendizado, onde um modelo treinado em grandes conjuntos de dados, como *ImageNet*, é ajustado para tarefas específicas com conjuntos de dados menores. O uso de modelos pré-treinados como o ResNet50 tem acelerado o desenvolvimento e a implementação de soluções em diversas aplicações de visão computacional.

4.1.2 DenseNet

DenseNet, ou *Dense Convolutional Network*, é uma arquitetura de rede neural profunda utilizada em tarefas de aprendizado de máquina, especialmente na visão computacional, proposta por Huang et al. [2017].

A principal ideia por trás do DenseNet é a conexão densa entre as camadas da rede. Em vez de simplesmente conectar camadas sequencialmente, como em arquiteturas tradicionais, as unidades em uma camada DenseNet recebem conexões diretas de todas as camadas anteriores. Isso cria uma rede densamente conectada, onde cada camada recebe informações diretamente de todas as camadas anteriores, promovendo o reuso eficiente de características e melhorando o fluxo de gradientes durante o treinamento.

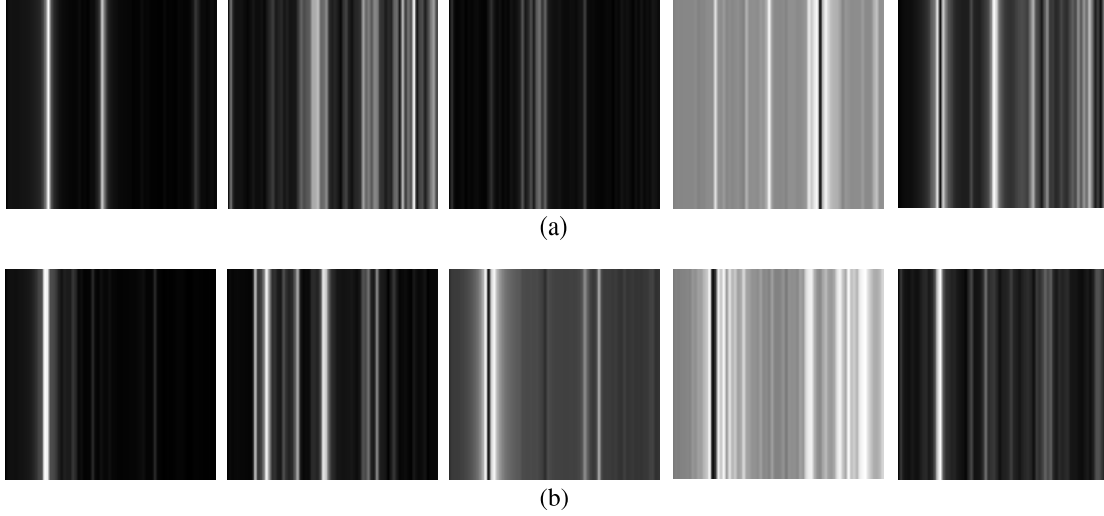


Figura 3: Imagens das grades sinusoidais: (a) exemplos no estado íntegro, (b) exemplos no estado com dano.

4.1.3 InceptionV3

InceptionV3 é uma arquitetura de rede neural convolucional desenvolvida pela equipe do Google Research. Ela foi projetada para tarefas de classificação de imagens e reconhecimento visual. O nome "Inception" se refere à inclusão de módulos inception na arquitetura, que são blocos de construção específicos projetados para capturar características em diferentes escalas e orientações dentro de uma imagem.

A arquitetura InceptionV3 é uma evolução das versões anteriores, como InceptionV1 e InceptionV2, e foi introduzida como parte do desafio ILSVRC (*ImageNet Large Scale Visual Recognition Challenge*) em 2015 (Szegedy et al. [2016]). Ela tem sido amplamente utilizada em diversas aplicações, incluindo transferência de aprendizado, detecção de objetos e segmentação de imagens, devido à sua capacidade de extrair características complexas e sua eficácia em tarefas de visão computacional.

5 Resultados e Discussão

A escolha da arquitetura da CNN é um fator fundamental que impacta no desempenho do modelo, considerando o seu conjunto de dados de entrada. Por isso, para treinamento e avaliação de modelos para detecção de dano da Ponte Old ADA foram selecionadas as arquiteturas Resnet50, a DenseNet e a InceptionV3, consideradas o estado da arte.

Antes de iniciar o processo de treinamento dos modelos, o conjunto de imagens com e sem dano foram divididos, aleatoriamente, em 75% para treinamento, 20% para validação e 5% para testes. Durante a fase treinamento, a CNN aprendeu a mapear características das imagens para classes com dano ou sem dano. Nesta etapa, cada modelo foi treinado com 50 épocas, considerando os pesos pré-treinados do *ImageNet*. Para fins de performance, o treinamento ocorreu em lote de 64 imagens.

Avaliando os modelos, foi possível observar que o DenseNet obteve o melhor desempenho com 95,06% de acurácia, com o conjunto de imagens de validação. Para o conjunto de testes também foi atingido 95,06% de acurácia. Os resultados da Tabela 1 evidenciam a capacidade do modelo em identificar padrões associados aos sinais que representam as respostas estruturais em vibração.

Tabela 1: Comparação dos resultados de acurácia dos modelos Resnet50, DenseNet e InceptionV3

		Modelos		
		Resnet50	DenseNet	InceptionV3
Acurácia	Validação	93,96%	95,06%	94,03%
	Teste	94,55%	95,06%	92,99%

A eficácia do modelo foi avaliada utilizando métricas como acurácia (proporção classificada corretamente em relação ao todo), precisão (proporção de verdadeiros positivos em relação à todas classificações positivas feitas pelo modelo), revocação (proporção de verdadeiros positivos em relação à todos que realmente são positivos) e f1-score (média harmônica da precisão e revocação), além da análise da matriz de confusão resultante. Os conjuntos de imagens de validação e teste foram fundamentais para garantir a generalização do modelo para imagens não conhecidas. Esses critérios foram determinantes para seleção do melhor modelo.

Considerando a seleção do modelo DenseNet, obteve-se o resultado de 95,76% de precisão, 92,99% de revocação e 94,37% de f1-score para imagens com danos. Já para as imagens sem danos, os resultados foram 94,51% de precisão, 96,73% de revocação e 95,61% de f1-score (Tabela 2).

Tabela 2: Métricas dos modelos - Validação

modelo	classe	precisão	revocação	f1-score
Resnet50	Com dano	93,66%	92,70%	93,18%
	Sem dano	94,20%	94,97%	94,58%
DenseNet	Com dano	95,76%	92,99%	94,37%
	Sem dano	94,51%	96,73%	95,61%
InceptionV3	Com dano	93,03%	93,58%	93,30%
	Sem dano	94,83%	94,39%	94,61%

Durante a avaliação do conjunto de testes, os resultados foram similares (Tabela 3). Para imagens com danos, os resultados foram de 95,78% de precisão, 92,98% de revocação e 94,36% de f1-score. Já para as imagens sem danos, teve-se 94,52% de precisão, 96,73% de revocação e 95,61% de f1-score.

Tabela 3: Métricas dos modelos - Testes

modelo	classe	precisão	revocação	f1-score
Resnet50	Com dano	94,12%	93,57%	93,84%
	Sem dano	94,88%	95,33%	95,10%
DenseNet	Com dano	95,78%	92,98%	94,36%
	Sem dano	94,52%	96,73%	95,61%
InceptionV3	Com dano	93,37%	90,64%	91,99%
	Sem dano	92,69%	94,86%	93,76%

Através da análise da matriz de confusão podemos fazer uma análise quantitativa referente a assertividade do modelo. Para o conjunto de validação, considerando o total de 685 imagens com dano, o modelo conseguiu acertar 637 casos e errar 48, enquanto para o total de 855 imagens sem dano, foi possível acertar 827 e errar 28 imagens (Figura 4(a)). Para o conjunto de testes, considerando o total de 171 imagens com dano, o modelo conseguiu acertar 159 casos e errar 12, enquanto para o total de 214 imagens sem dano, foi possível acertar 207 e errar apenas 7 imagens (Figura 4(b)).

6 Considerações Finais

Neste trabalho, foi proposta uma abordagem baseada em inteligência artificial para detecção de danos estruturais na Ponte Old ADA. A abordagem metodológica compreendeu o pré-processamento dos sinais de aceleração da estrutura, a conversão desses sinais em representações visuais de padrões sinusoidais em grades, seguida da utilização de redes neurais artificiais para categorizar o estado da ponte com ou sem dano.

A partir da avaliação de 3 arquiteturas, consideradas o estado da arte, obtivemos a acurácia de 95,06% com o modelo pré-treinado do Densenet, sendo um resultado satisfatório para a abordagem proposta. Destaca-se que foi feita uma análise individual de cada sensor, ou seja, foi desconsiderado a combinação de acelerômetros na entrada dos modelos. Assim, a localização dos sensores ou intensidade de vibração da estrutura não impactaram na tarefa de classificação de dano.

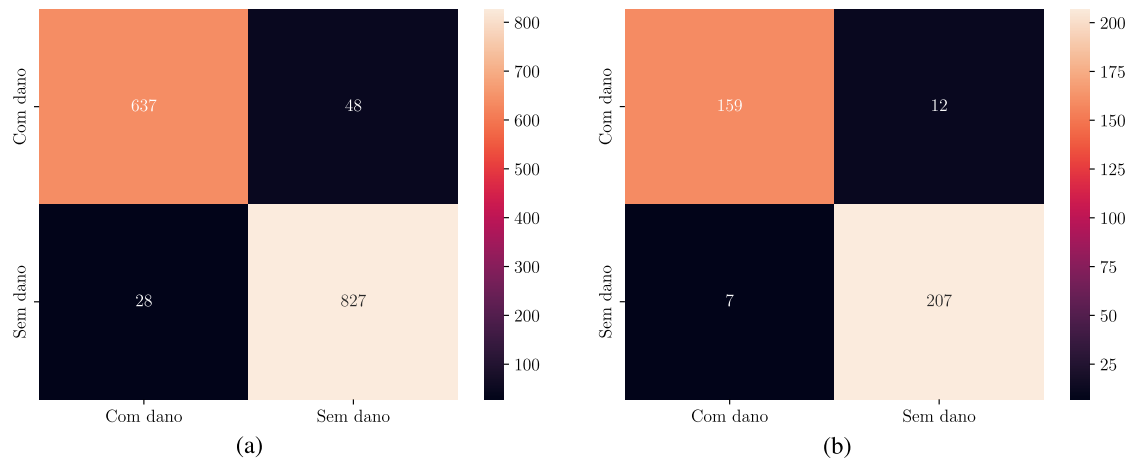


Figura 4: Matrizes de Confusão do modelo Densenet: (a) Validação, (b) Teste

Ainda há a necessidade aprimoramentos da metodologia apresentada, como: a expansão do conjunto de dados, a exploração de técnicas de aumento de dados e ajustes na arquitetura da CNN. Além disso, a abordagem poderia ser aprimorada acrescentando a localização e quantificação dos danos na estrutura. Isso poderia ser atingindo a partir da ampliação do conjunto de dados de treinamento a partir de mapeamentos tridimensionais usando nuvens de pontos 3D (em inglês, 3D point cloud). Dessa forma, poderiam ser simulados perturbações na estrutura 3D com diferentes níveis de danos na estrutura Zhang and Yuen [2022].

Referências

- Yang Zhang and Ka-Veng Yuen. Review of artificial intelligence-based bridge damage detection. *Advances in Mechanical Engineering*, 14(9):16878132221122770, 2022. doi:10.1177/16878132221122770.
- Melvin Shibu, Kukatlappalli Pradeep Kumar, Vinay Jha Pillai, Hari Murthy, and Sarath Chandra. Structural health monitoring using ai and ml based multimodal sensors data. *Measurement: Sensors*, 27:100762, 2023. ISSN 2665-9174. doi:https://doi.org/10.1016/j.measen.2023.100762.
- Jordan C. Weinstein, Masoud Sanayei, and Brian R. Brenner. Bridge damage identification using artificial neural networks. *Journal of Bridge Engineering*, 23(11):04018084, 2018. doi:10.1061/(ASCE)BE.1943-5592.0001302.
- Seyyed Pooya Hekmati Athar, Mohammad Taheri, Jameson Secrist, and Hossein Taheri. Neural network for structural health monitoring with combined direct and indirect methods. *Journal of Applied Remote Sensing*, 14(1):014511, 2020. doi:10.1117/1.JRS.14.014511.
- Hooman Nick, Armin Aziminejad, Mir Hamid Hosseini, and Karim Laknejadi. Damage identification in steel girder bridges using modal strain energy-based damage index method and artificial neural network. *Engineering Failure Analysis*, 119:105010, 2021. ISSN 1350-6307. doi:10.1016/j.engfailanal.2020.105010.
- Pasquale Santaniello and Paolo Russo. Bridge damage identification using deep neural networks on timendash;frequency signals representation. *Sensors*, 23(13), 2023. ISSN 1424-8220. doi:10.3390/s23136152.
- Chul-Woo Kim, Feng-Liang Zhang, Kai-Chun Chang, Patrick John McGetrick, and Yoshinao Goi. Ambient and vehicle-induced vibration data of a steel truss bridge subject to artificial damage. *Journal of Bridge Engineering*, 2021a. doi:10.1061/(ASCE)BE.1943-5592.0001730.
- Chul-Woo Kim, Feng-Liang Zhang, Kai-Chun Chang, Patrick John McGetrick, and Yoshinao Goi. Old_ada_bridge-damage_vibration_data. *Mendeley Data*, 2021b. doi:10.17632/sc8whx4pvm.2.
- Yi He, Judy P. Yang, and Yi-Feng Li. A three-stage automated modal identification framework for bridge parameters based on frequency uncertainty and density clustering. *Engineering Structures*, 255:113891, 2022. ISSN 0141-0296. doi:10.1016/j.engstruct.2022.113891.
- Ian Goodfellow, Yoshua Bengio, and Aaron Courville. Deep learning. *The MIT Press*, 2016.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

- Gao Huang, Zhuang Liu, Laurens van der Maaten, and Kilian Q. Weinberger. Densely connected convolutional networks. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4700–4708, 2017.
- Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jon Shlens, and Zbigniew Wojna. Rethinking the inception architecture for computer vision. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2818–2826, 2016.